

■ Análisis Topológico de Escuelas en CDMX

Documentación técnica completa del proyecto

Dashboard interactivo · Homología Persistente · Análisis de Cobertura

5,587	5	16	2
Escuelas analizadas	Niveles educativos	Alcaldías cubiertas	Sectores (público/privado)

Este documento describe en detalle cada componente del proyecto: datos de entrada, procesamiento, cálculos de homología persistente, visualizaciones del dashboard y metodología de identificación de zonas de déficit educativo.

Fuente de datos: DENUÉ — Directorio Estadístico Nacional de Unidades Económicas (INEGI)

Tecnología principal: Ripser (homología persistente), Streamlit (dashboard), Folium (mapas)

Rama matemática: Análisis Topológico de Datos (TDA) — Homología persistente H_0 y H_1

1. Estructura del Proyecto

El proyecto está organizado en tres grandes áreas:

Proyecto-Topologia/ Raíz

- denue_inegi_61_.csv Dataset crudo DENU: 10,448 registros
- requirements.txt Dependencias Python (13 librerías)
- data/processed/ Datos procesados y resultados TDA
 - ■■■■ escuelas_cdmx.parquet 5,587 escuelas filtradas y georreferenciadas
 - ■■■■ tda_results/ 6 pickles con diagramas de persistencia pre-calculados
 - ■■■■ preescolar.pkl Resultados TDA nivel preescolar
 - ■■■■ primaria.pkl Resultados TDA nivel primaria
 - ■■■■ secundaria.pkl Resultados TDA nivel secundaria
 - ■■■■ media_superior.pkl Resultados TDA nivel media superior
 - ■■■■ media_tecnica.pkl Resultados TDA nivel media técnica
 - ■■■■ todas.pkl Resultados TDA con todos los niveles
- notebooks/ Análisis exploratorio y cálculos paso a paso
 - ■■■■ 01_data_prep.ipynb Preparación y limpieza de datos
 - ■■■■ 02_eda.ipynb Análisis exploratorio y elección de parámetros
 - ■■■■ 03_tda_persistencia.ipynb Cálculo de homología persistente
 - ■■■■ 04_interpretacion.ipynb Localización geográfica de huecos
- dashboard/ Aplicación web interactiva (Streamlit)
- app.py Portada con métricas globales
- pages/ Páginas del dashboard
 - ■■■■ 1_Panorama.py Mapa explorador con filtros
 - ■■■■ 2_Complejos_Simpliciales.py Visualización del complejo Vietoris-Rips
 - ■■■■ 3_Persistencia.py Diagramas de persistencia, barcodes, Betti
 - ■■■■ 4_Huecos_de_Cobertura.py Mapa de zonas con déficit educativo
- utils/ Módulos compartidos
- data_loader.py Carga de datos y caché
- tda.py Motor de cálculo TDA
- plotting.py Funciones de visualización

2. Datos de Entrada y Procesados

2.1 Dataset crudo: denue_inegi_61_.csv

Archivo CSV del Directorio Estadístico Nacional de Unidades Económicas (DENUE) del INEGI, acotado al subsector 61 (Servicios Educativos) de la Ciudad de México. Contiene 10,448 registros con información de establecimientos educativos de todos los niveles.

Columnas principales del CSV crudo:

Campo	Tipo	Descripción
nom_estab	texto	Nombre del establecimiento
codigo_act	texto	Clave SCIAN de 6 dígitos (categoría de actividad)
nombre_act	texto	Descripción completa de la actividad económica
per_ocu	entero	Personal ocupado en el establecimiento
cve_ent	texto	Clave de entidad federativa (09 = CDMX)
entidad	texto	Nombre de la entidad (Ciudad de México)
municipio	texto	Alcaldía o municipio
latitud	decimal	Latitud WGS84 (grados decimales)
longitud	decimal	Longitud WGS84 (grados decimales)
fecha_alta	texto	Fecha de registro en DENUE

2.2 Categorías SCIAN incluidas

De los 10,448 registros originales se filtran únicamente las 12 categorías correspondientes a educación básica y media. Cada categoría combina nivel educativo y sector.

Código SCIAN	Descripción	Nivel asignado	Sector
611111	Escuelas de educación preescolar del sector público	preescolar	público
611112	Escuelas de educación preescolar del sector privado	preescolar	privado
611121	Escuelas de educación primaria del sector público	primaria	público
611122	Escuelas de educación primaria del sector privado	primaria	privado
611131	Escuelas de educación secundaria general del sector público	secundaria	público
611132	Escuelas de educación secundaria general del sector privado	secundaria	privado
611141	Escuelas de bachillerato general del sector público	media_superior	público

Código SCIAN	Descripción	Nivel asignado	Sector
611142	Escuelas de bachillerato general del sector privado	media_superior	privado
611151	Escuelas del nivel medio superior técnico terminal del sector público	media_tecnica	público
611152	Escuelas del nivel medio superior técnico terminal del sector privado	media_tecnica	privado
611161	Escuelas de formación para el trabajo del sector público	media_tecnica	público
611162	Escuelas de formación para el trabajo del sector privado	media_tecnica	privado

2.3 Dataset procesado: escuelas_cdmx.parquet

Resultado del pipeline de preparación de datos. Formato Apache Parquet (binario comprimido). Contiene 5,587 escuelas con columnas derivadas de nivel educativo, sector y coordenadas métricas.

Columna	Tipo	Rango / Valores	Descripción
nivel	texto	preescolar, primaria, secundaria, media_superior, media_tecnica	Nivel educativo (derivado)
sector	texto	público, privado	Sector educativo (derivado)
latitud	decimal	[19.0, 19.7]	Latitud en grados WGS84
longitud	decimal	[-99.4, -98.9]	Longitud en grados WGS84
x_utm	decimal	~470,000 – 510,000 m	Coordenada Este UTM zona 14N (EPSG:32614)
y_utm	decimal	~2,120,000 – 2,170,000 m	Coordenada Norte UTM zona 14N (EPSG:32614)
municipio	texto	16 alcaldías	Alcaldía de CDMX

Distribución por nivel educativo:

Nivel	Escuelas	% del total
Preescolar	1,467	26.3%
Primaria	2,154	38.6%
Secundaria	1,135	20.3%
Media Superior	641	11.5%
Media Técnica	190	3.4%
TOTAL	5,587	100%

3. Notebooks de Análisis

El análisis se desarrolla secuencialmente en cuatro notebooks Jupyter. Cada uno produce artefactos que consume el siguiente, formando un pipeline completo.

3.1 01_data_prep.ipynb — Preparación de Datos

Objetivo: Transformar el CSV crudo del DENUE en un dataset limpio y georreferenciado en metros.

Pa so	Etap a	Descripción
1	Carga del CSV	Lee denue_inegi_61_.csv con encoding latin-1. Detecta los 10,448 registros originales.
2	Filtro geográfico	Filtra por entidad = 'Ciudad de México'. Aplica bounding box: latitud $\in$ [19.0, 19.7], longitud $\in$ [-99.4, -98.9]. Descarta puntos fuera de CDMX.
3	Filtro por categoría	Conserva solo los 12 códigos SCIAN de educación básica y media (ver tabla sección 2.2). Resultado: 5,587 escuelas válidas.
4	Derivación de nivel y sector	Parsea el campo nombre_act para asignar nivel (preescolar/primaria/secundaria/media_superior/media_tecnica) y sector (público/privado) a cada registro.
5	Reproyección UTM	Convierte coordenadas WGS84 (grados) a UTM zona 14N (metros) usando pyproj.Transformer con EPSG:4326→EPSG:32614. Las nuevas columnas x_utm y y_utm expresan la posición en metros, necesario para que las distancias del análisis topológico sean métricamente correctas.
6	Exportación	Guarda el resultado en data/processed/escuelas_cdmx.parquet usando pyarrow. Formato Parquet elegido por velocidad de lectura y compresión eficiente.

3.2 02_eda.ipynb — Análisis Exploratorio

Objetivo: Entender la distribución espacial de las escuelas y elegir el parámetro umbral ϵ para el análisis topológico.

Análisis realizados:

- **Tablas de frecuencia:** Conteos cruzados nivel $\times$ sector y distribución por alcaldía. Revela que Iztapalapa (~600), Gustavo A. Madero (~550) y Cuauhtémoc (~450) concentran mayor cobertura.
- **Mapa exploratorio:** Folium MarkerCluster con muestra aleatoria de 2,000 escuelas. Cada punto tiene color según nivel educativo.
- **Distancias al k-ésimo vecino más cercano (kNN):** Calcula distancias al vecino 1, 5 y 10 para cada nivel usando sklearn.neighbors.NearestNeighbors. Genera histogramas interactivos con Plotly.
- **Selección de umbral ϵ :** Basada en los percentiles de distancias kNN. El percentil 90 del vecino $k=10$ está ~2,200 m, lo que sugiere $\epsilon = 2,500\text{--}3,000$ m como escala de análisis razonable (radio de desplazamiento urbano a pie).

k-vecino	Mediana	Percentil 75	Percentil 90
k=1	~200 m	~400 m	~700 m
k=5	~400 m	~800 m	~1,500 m
k=10	~600 m	~1,200 m	~2,200 m

Distancias kNN aproximadas (promedio entre todos los niveles)

Conclusión del EDA: Se elige $\epsilon = 3,000$ m como umbral máximo para el análisis Vietoris-Rips. Este valor conecta la mayoría de las escuelas en un mismo nivel y corresponde a ~35 minutos caminando, un radio de acceso razonable en contexto urbano de CDMX.

3.3 03_tda_persistencia.ipynb — Homología Persistente

Objetivo: Calcular los diagramas de persistencia H_1 y H_0 para cada nivel educativo y guardar los resultados para uso en el dashboard.

Parámetros del cálculo:

Parámetro	Valor	Significado
maxdim	1	Calcula hasta homología de dimensión 1 (H_1 y H_0). H_1 = componentes conexas, H_0 = 1-ciclos (huecos).
thresh	3,000 m	Radio máximo ϵ . Ninguna arista del complejo supera esta distancia.
do_cocycles	True	Devuelve 1-cocadenas (cociclos) que permiten localizar geográficamente cada hueco H_0 .
Submuestreo	Ninguno	En los notebooks se usa la totalidad de puntos por nivel (no se reduce).

Proceso por cada nivel:

- Extrae coordenadas UTM (x_utm, y_utm) del parquet para el nivel.
- Llama a `rips(X, maxdim=1, thresh=3000, do_cocycles=True)`.
- Obtiene `dgms = [H0_array, H1_array]` donde cada fila es (birth, death).
- Guarda resultado como pickle en `data/processed/tda_results/{nivel}.pkl`.

Visualizaciones generadas:

Visualización	Descripción
Scatter espacial (2×3 grid)	Posición UTM de las escuelas por nivel. Muestra densidad geográfica.
Diagramas de persistencia (2×3 grid)	H_1 en azul, H_0 en naranja. Puntos lejos de la diagonal = features persistentes.
Barcode H_1 (2×3 grid)	Top-15 features por persistencia. Barra más larga = hueco más robusto.
Lifetime plot (2×3 grid)	Ejes: birth vs. persistencia. Línea gris = 25% de máximo (umbral de ruido).
Curvas de Betti	$\beta_1(\epsilon)$ y $\beta_0(\epsilon)$ en función del radio. Muestra evolución de la topología.

Visualización	Descripción
Barras de máxima persistencia	Comparación entre niveles: media técnica suele tener mayor persistencia (red más escasa).

Resultados típicos del cálculo:

Nivel	N escuelas	H■ features aprox.	Max. persistencia H■
Preescolar	1,467	~50	~1,200 m
Primaria	2,154	~80	~1,500 m
Secundaria	1,135	~40	~1,300 m
Media Superior	641	~25	~1,800 m
Media Técnica	190	~8	~2,500 m
Todas	5,587	~300+	~2,000 m

Nota: A mayor escasez de red → mayor persistencia de los huecos → zonas de cobertura más grandes y robustas.

3.4 04_interpretacion.ipynb — Localización Geográfica de Huecos

Objetivo: Proyectar los huecos topológicos detectados por H■ sobre un mapa real de CDMX para identificar zonas con déficit de cobertura educativa.

Función principal — `hole_centroids(r, top_k=5)`:

- Extrae el diagrama H■ del resultado de ripser.
- Ordena features por persistencia (death – birth) descendente.
- Para cada uno de los top-k features:
 - a) Obtiene el cociclo: lista de tuplas (i, j, valor) que forman el 1-ciclo.
 - b) Extrae vértices únicos: `np.unique(coc[:, :2].ravel())`.
 - c) Calcula centroide geométrico: `X[verts].mean(axis=0)` en coordenadas UTM.
 - d) Convierte centroide a lat/lon con `utm_to_latlon()` para Folium.
- Retorna lista de dicts con birth, death, persistencia, centroide UTM, n_vértices.

Mapa de huecos (Folium):

- Un FeatureGroup por nivel educativo con LayerControl para mostrar/ocultar capas.
- Por cada hueco: círculo grande con radio = persistencia/2 metros (visualiza el tamaño del hueco).
- CircleMarker en el centroide del hueco con popup interactivo.
- Popup muestra: birth, death, persistencia (metros), número de vértices del cociclo.

Comparación con DBSCAN:

El notebook incluye una sección comparativa: se ejecuta DBSCAN ($\epsilon=500$ m, `min_samples=5`) sobre las escuelas de nivel primaria. DBSCAN identifica agrupaciones densas de escuelas, pero NO detecta zonas de déficit rodeadas por escuelas. TDA (H■) es complementario: identifica exactamente esas regiones con carencia aunque existan escuelas en los alrededores.

4. Módulos Python del Dashboard

El dashboard (dashboard/) está construido con Streamlit y se divide en módulos de utilidad compartidos (utils/) y páginas independientes (pages/).

4.1 dashboard/utils/data_loader.py — Carga de Datos y Caché

Centraliza la carga de datos y define las constantes de configuración usadas en todo el dashboard. Usa el sistema de caché de Streamlit para no releer archivos en cada interacción.

Constantes definidas:

Constante	Valor	Uso
NIVELES	['preescolar', 'primaria', 'secundaria', 'media_superior', 'media_tecnica']	Lista canónica de niveles para iteración y filtros
SECTORES	['público', 'privado']	Opciones de sector disponibles
NIVEL_COLOR['pre escolar']	#2ca02c (verde)	Color de marcador para preescolar
NIVEL_COLOR['primaria']	#1f77b4 (azul)	Color de marcador para primaria
NIVEL_COLOR['secundaria']	#ff7f0e (naranja)	Color de marcador para secundaria
NIVEL_COLOR['media_superior']	#d62728 (rojo)	Color de marcador para media superior
NIVEL_COLOR['media_tecnica']	#9467bd (púrpura)	Color de marcador para media técnica

Funciones:

Función	Parámetros	Retorna	Descripción
load_escuelas()	—	DataFrame	Lee escuelas_cdmx.parquet con @st.cache_data. Retorna las 5,587 escuelas.
load_tda(nivel)	nivel: str	dict o None	Lee el pickle de resultados TDA para el nivel dado. Retorna None si no existe.
available_tda_levels()	—	list[str]	Devuelve lista de niveles que tienen archivos .pkl pre-computados.

4.2 dashboard/utils/tda.py — Motor de Cálculo TDA

Contiene toda la lógica matemática del análisis topológico. Implementa submuestreo inteligente, cálculo de homología persistente con ripser, curvas de Betti y extracción de centroides de huecos mediante

cociclos.

Función 1: `landmark_sample(X, max_n=1500, seed=0)`

Reduce el número de puntos cuando $N > \text{max_n}$ para hacer manejable el cálculo de Vietoris-Rips. El complejo Vietoris-Rips tiene complejidad cuadrática $O(N^2)$ en número de aristas y cúbica $O(N^3)$ en el caso general, lo que hace inviable procesar miles de puntos en tiempo real.

Condición	Acción	Resultado
$\text{len}(X) \leq \text{max_n}$	Retorna X sin cambios	Dataset completo, sin pérdida
$\text{len}(X) > \text{max_n}$	Aplica KMeans($n_clusters=\text{max_n}$)	max_n centroides representativos

Función 2: `compute_vr(X, thresh, max_n)` — con `@st.cache_resource`

Función principal de cálculo. Ejecuta el pipeline completo de homología persistente:

- Submuestrea con `landmark_sample(X, max_n)`.
- Llama a `ripser(Xs, maxdim=1, thresh=thresh, do_cocycles=True)`.
- El parámetro `maxdim=1` limita el cálculo a H_0 y H_1 (componentes y ciclos 1-dimensionales).
- El parámetro `do_cocycles=True` activa el cómputo de cocadenas para localización posterior.
- Retorna dict con los puntos submuestreados, diagramas `dgms=[H0, H1]`, cociclos y parámetros.

Función 3: `betti_curves(dgms, eps_grid)`

Calcula las curvas de Betti $\beta_0(\epsilon)$ y $\beta_1(\epsilon)$ a lo largo de una grilla de valores de escala.

Para cada valor ϵ en `eps_grid`, cuenta los features del diagrama que están 'vivos' en esa escala: un feature (birth, death) está vivo si $\text{birth} \leq \epsilon < \text{death}$. β_0 cuenta componentes conexas; β_1 cuenta 1-ciclos (huecos). Retorna array de forma `(len(eps_grid), 2)`.

Función 4: `top_h1_with_cocycles(r, k=5)`

Extrae los k huecos H_1 más persistentes y calcula su ubicación geográfica mediante los cociclos:

- Ordena features H_1 por persistencia descendente ($\text{death} - \text{birth}$, tomando `thresh` si $\text{death}=\infty$).
- Para cada uno de los top-k: extrae los índices de vértices del cociclo correspondiente.
- Calcula el centroide geométrico como promedio de coordenadas UTM de los vértices.
- Retorna lista de dicts con birth, death, persistencia, centroide UTM, coordenadas de vértices, `n_vértices`.

4.3 `dashboard/utils/plotting.py` — Visualizaciones

Proporciona todas las funciones de visualización usadas por las páginas del dashboard. Combina Plotly (gráficos estadísticos) y Folium (mapas geográficos).

Transformación de coordenadas:

`utm_to_latlon(x, y)`: Convierte coordenadas UTM zona 14N (EPSG:32614) a latitud/longitud WGS84 (EPSG:4326). Usa `pyproj.Transformer` con `always_xy=True`. Necesario porque Folium trabaja en grados, pero el análisis TDA en metros.

Gráficos Plotly:

Función	Descripción	Ejes
<code>persistence_diagram(dgms, thresh)</code>	Diagrama de persistencia clásico. Puntos H en azul, H en naranja. Línea diagonal gris = referencia (birth=death). Distancia a la diagonal = persistencia.	X: birth (m), Y: death (m)
<code>barcode(dgms, thresh, dim=1)</code>	Barcode: una barra horizontal por feature H . Longitud = persistencia. Ordenadas de mayor a menor persistencia. Features con death= ∞ se extienden hasta thresh.	X: ϵ (m), Y: índice de feature
<code>betti_curve_fig(eps, betti)</code>	Dos líneas superpuestas: $\beta(\epsilon)$ en azul (eje Y izquierdo) y $\beta(\epsilon)$ en naranja (eje Y derecho). Muestra cómo evoluciona la topología al aumentar ϵ .	X: ϵ (m), Y: número de Betti

Mapas Folium:

Función	Descripción
<code>base_map(zoom=11)</code>	Crea mapa Folium centrado en CDMX [19.4326, -99.1332] con tiles CartoDB Positron.
<code>add_school_layer(m, df, sample_max=1500)</code>	Agrega capa MarkerCluster con CircleMarkers por escuela. Color según NIVEL_COLOR. Tooltip con nivel, sector y nombre del establecimiento.
<code>add_holes_layer(m, holes, color, label)</code>	Agrega capa de huecos: círculo grande (radio = persistencia/2 en metros) y CircleMarker en centroide con popup de metadatos TDA.

5. Páginas del Dashboard Streamlit

El dashboard se ejecuta con `streamlit run dashboard/app.py` y presenta cinco secciones navegables. Cada página combina controles interactivos en la barra lateral con visualizaciones en el área principal.

5.0 app.py — Portada Principal

Propósito: Vista de bienvenida con métricas globales del dataset.

- Cuatro métricas destacadas: total de escuelas (5,587), niveles (5), alcaldías (16), sectores (2).
- Tabla de conteos cruzados nivel × sector con totales por fila y columna.
- Tabla de categorías SCIAN incluidas con código, descripción, nivel asignado y sector.
- Leyenda de colores por nivel educativo (usada consistentemente en todo el dashboard).

5.1 1_Panorama.py — Exploración Geográfica

Propósito: Mapa interactivo filtrable para explorar la distribución espacial de las escuelas.

Filtros (barra lateral):

Control	Tipo	Opciones
Nivel educativo	Multiselect	preescolar, primaria, secundaria, media_superior, media_tecnica
Sector	Multiselect	público, privado
Alcaldía	Multiselect	Las 16 alcaldías de CDMX
Máx. puntos a dibujar	Slider	200 – 5,000 (default 1,500)

Visualizaciones (columna principal 3/4 + columna derecha 1/4):

- Mapa Folium con MarkerCluster: los marcadores se agrupan automáticamente al hacer zoom out. Al hacer zoom in, se expanden mostrando cada escuela con su tooltip.
- Gráfico de barras horizontal: conteo de escuelas por nivel educativo con colores NIVEL_COLOR.
- Gráfico de barras horizontal: top-10 alcaldías por número de escuelas, ordenado descendente.

5.2 2_Complejos_Simpliciales.py — Visualización Vietoris-Rips

Propósito: Visualizar interactivamente la construcción del complejo Vietoris-Rips al variar el parámetro ϵ , mostrando vértices, aristas y triángulos sobre el mapa de CDMX.

¿Qué es un complejo Vietoris-Rips?

Dado un conjunto de puntos (escuelas) y un radio ϵ :

- Vértice (0-símplex): cada escuela es un punto.
- Arista (1-símplex): se traza una línea entre dos escuelas si su distancia $\leq \epsilon$.
- Triángulo (2-símplex): se rellena el triángulo formado por tres escuelas si todas las distancias entre pares $\leq \epsilon$. El complejo captura la 'forma' de la nube de puntos a la escala ϵ .

Controles:

Control	Rango	Efecto
Nivel educativo	Todas + 5 niveles	Filtra qué escuelas se incluyen como vértices
Sector	Ambos, público, privado	Filtra por tipo de gestión
Puntos máx.	50 – 600 (default 250)	Submuestreo de vértices para rendimiento
ϵ radio (metros)	0 – 4,000 (default 800)	Distancia máxima para conectar dos escuelas
Mostrar discos de  ech	Checkbox	Dibuja círculos de radio $\epsilon/2$ alrededor de cada vértice

Construcción del complejo (algoritmo):

- Filtra escuelas por nivel y sector.
- Submuestra con `landmark_sample(X, max_pts)`.
- Construye aristas: `scipy.spatial.cKDTree.query_pairs(r= $\epsilon$ )` — devuelve todos los pares (i,j) con distancia $\leq \epsilon$.
- Construye triángulos (solo si $n \leq 200$ vértices): para cada par de aristas (i,j) y (i,k) verifica si existe arista (j,k). Si existe, forma triángulo (i,j,k).
- Convierte coordenadas UTM $\rightarrow$ lat/lon para visualización en Folium.
- Dibuja capas: triángulos semitransparentes $\rightarrow$ aristas $\rightarrow$ discos ech $\rightarrow$ vértices con LayerControl.

5.3 3_Persistencia.py — Análisis de Persistencia

Propósito: Explorar los diagramas de persistencia, barcodes y curvas de Betti para cada nivel educativo, tanto en modo pre-computado (instantáneo) como recalculando con filtros personalizados.

Dos modos de operación:

Modo	Descripción	Velocidad
Pre-computado por nivel	Carga el pickle pre-calculado del nivel seleccionado (preescolar, primaria, secundaria, media_superior, media_tecnica, todas). Resultados instantáneos.	Inmediata
Recalcular con filtros	Permite combinar niveles y sectores, ajustar umbral ϵ (500–5,000 m) y número de landmarks (200–2,000). Recalcula con ripser en tiempo real. Requiere mínimo 3 puntos.	Segundos (según n)

Métricas mostradas:

- H_0 features: número de componentes conexas detectadas.
- H_1 features: número de 1-ciclos (huecos topológicos) detectados.
- Hueco más persistente: $\max(\text{death} - \text{birth})$ sobre todos los features H_1 .
- Persistencia media H_1 : promedio de persistencias de todos los huecos.

Tres pestañas de visualización:

Pestaña	Contenido	Interpretación
Diagrama de persistencia	Scatter plot con birth en X y death en Y. Línea diagonal gris = referencia.	Puntos lejanos a la diagonal → features robustos (no son ruido).
Barcode H■	Barras horizontales ordenadas por persistencia. Altura del panel escala con número de features.	Barras largas = huecos topológicamente significativos.
Curvas de Betti	$\beta_0(\epsilon)$ azul (eje Y izquierdo) y $\beta_1(\epsilon)$ naranja (eje Y derecho) en función de ϵ .	Permite ver en qué escala surgen y desaparecen los huecos.

5.4 4_Huecos_de_Cobertura.py — Mapa de Déficit Educativo

Propósito: Página central del análisis: localiza geográficamente los huecos H■ más persistentes sobre el mapa de CDMX y presenta una tabla con coordenadas y metadatos para priorizar zonas de intervención.

Controles:

Control	Tipo	Descripción
Niveles a analizar	Multiselect	Selección múltiple de niveles; puede incluir 'todas' (default: primaria, secundaria)
Sector	Radio button	Ambos (usa pre-computado) / público / privado (recalcula sobre subconjunto)
Top-K huecos	Slider 1–10	Número de huecos a mostrar por nivel (default: 5)
Mostrar escuelas	Checkbox	Si activo, superpone capa con 800 escuelas muestreadas del nivel

Mapa interactivo:

- Base CDMX con tiles CartoDB Positron.
- Por cada nivel seleccionado: FeatureGroup con LayerControl para mostrar/ocultar.
- Por cada hueco: círculo con radio = persistencia/2 metros (proporcional al tamaño del hueco).
- CircleMarker en el centroide del hueco con popup: birth (m), death (m), persistencia (m), n_vértices.
- Si 'Mostrar escuelas' activo: capa adicional con MarkerCluster de escuelas del nivel.

Tabla de resultados:

Columna derecha con DataFrame ordenado por persistencia descendente. Columnas: nivel, sector, latitud, longitud, birth (m), death (m), persistencia (m), n_vértices. La fila superior identifica el hueco más significativo de toda la selección y se destaca con una caja de información.

Interpretación del déficit: un hueco H■ persistente identifica una región geográfica rodeada por escuelas del nivel analizado, pero que internamente carece de cobertura. A mayor persistencia → mayor tamaño del déficit → mayor prioridad de intervención. La ubicación del centroide indica dónde abrir un nuevo plantel tendría mayor impacto.

6. Fundamentos Matemáticos

6.1 Homología Persistente

El Análisis Topológico de Datos (TDA) aplica herramientas de topología algebraica a nubes de puntos. La homología persistente mide cómo cambian las características topológicas de un espacio al variar un parámetro de escala ϵ .

Complejo Vietoris-Rips $VR(X, \epsilon)$:

Dado un conjunto X de puntos (escuelas) y un radio $\epsilon \geq 0$, el complejo Vietoris-Rips es el complejo simplicial formado por todos los subconjuntos $\sigma \subseteq X$ tales que la distancia entre cualquier par de puntos en σ sea $\leq \epsilon$. Al aumentar ϵ de 0 a ∞ , se obtiene una filtración: $VR(X, 0) \subseteq VR(X, \epsilon_1) \subseteq VR(X, \epsilon_2) \subseteq \dots$

Grupos de homología:

Grupo	Dimensión	Significado topológico	En el contexto de escuelas
H_0	0	Componentes conexas	Grupos de escuelas mutuamente alcanzables a distancia $\leq \epsilon$
H_1	1	1-ciclos (agujeros)	Regiones rodeadas por escuelas pero sin cobertura interna
H_2	2	2-ciclos (cavidades)	No calculado en este proyecto (maxdim=1)

Diagrama de persistencia:

Cada feature topológico nace a un radio ϵ_b (birth) y muere a un radio ϵ_d (death). El par (birth, death) se representa como un punto en el plano. La diagonal birth = death actúa como referencia: puntos cercanos a la diagonal tienen baja persistencia (ruido topológico); puntos lejanos tienen alta persistencia (estructura real de los datos).

Persistencia de un feature: $\text{pers} = \text{death} - \text{birth}$. Para features con $\text{death} = \infty$ (nunca mueren dentro del umbral), se usa thresh como valor de muerte.

6.2 Números de Betti

El k -ésimo número de Betti $\beta_k(\epsilon)$ cuenta el número de features H_k vivos a la escala ϵ . Un feature (birth, death) está vivo en ϵ si $\text{birth} \leq \epsilon < \text{death}$.

Número	Descripción	Interpretación en ϵ pequeño	Interpretación en ϵ grande
$\beta_0(\epsilon)$	Componentes conexas	Alto: cada escuela es un componente	Decrece hasta 1 cuando toda la ciudad se conecta
$\beta_1(\epsilon)$	Huecos 1-dimensionales	0: no hay ciclos con pocas conexiones	Sube al aparecer ciclos, luego baja al llenarse

6.3 Cociclos y Localización

La librería Ripser con `do_cocycles=True` devuelve, para cada feature H_i , una 1-cocadena: un conjunto de aristas (i, j) del complejo que 'detectan' el ciclo. Los vértices de estas aristas delimitan geométricamente la zona del hueco. El centroide de estos vértices da la ubicación geográfica del déficit de cobertura.

6.4 Relación con radio de cobertura urbana

La elección de $\epsilon = 3,000$ m como umbral de análisis se fundamenta en la escala humana: 3 km equivalen aproximadamente a 35-40 minutos caminando, rango típico de desplazamiento en zonas urbanas de CDMX. Los huecos H_i detectados a esta escala representan áreas donde ninguna escuela del nivel analizado está accesible en ese tiempo desde el interior del hueco.

7. Dependencias y Librerías

Librería	Versión mín.	Función en el proyecto
pandas	≥ 2.0	Procesamiento del CSV y parquet; filtros y agrupaciones en el dashboard
numpy	≥ 1.24	Operaciones matriciales, cálculo de centroides, arreglos de coordenadas
pyproj	≥ 3.6	Transformación de coordenadas WGS84 $\leftrightarrow$ UTM 14N (EPSG:4326 $\leftrightarrow$ EPSG:32614)
shapely	≥ 2.0	Geometría vectorial (incluida por compatibilidad con folium/geopandas)
scikit-learn	≥ 1.3	KMeans para submuestreo (landmark_sample); NearestNeighbors para kNN en EDA
riper	≥ 0.6	Cálculo del complejo Vietoris-Rips y homología persistente (motor central del TDA)
persim	≥ 0.3	Métricas de distancia entre diagramas de persistencia (wasserstein, bottleneck)
folium	≥ 0.15	Mapas interactivos HTML con OSM/CartoDB; MarkerCluster, FeatureGroup, LayerControl
streamlit	≥ 1.30	Framework del dashboard web interactivo; cache, widgets, layout de páginas
streamlit-folium	≥ 0.18	Integración de mapas Folium dentro del entorno Streamlit
plotly	≥ 5.20	Diagramas de persistencia, barcodes, curvas de Betti y gráficos de barras
pyarrow	≥ 14	Lectura y escritura del formato Parquet para el dataset procesado
scipy	implícita	cKDTree para búsqueda eficiente de pares de puntos en Complejos Simpliciales

8. Pipeline Completo del Proyecto

denue_inegi_61.csv	ENTRADA	Dataset crudo DENUE subsector 61 CDMX — 10,448 registros
Notebook	01_data_prep	Filtra CDMX + 12 categorías SCIAN → re proyecta UTM → exporta parquet
Artefacto	escuelas_cdmx.parquet	5,587 escuelas con coordenadas UTM y etiquetas nivel/sector
Notebook	02_eda	Análisis distribucional + kNN distances → justifica $\epsilon = 3,000$ m
Notebook	03_tda_persistencia	riper() por nivel → diagramas $H_{\blacksquare}/H_{\blacksquare}$ + visualizaciones matplotlib
Artefacto	tda_results/*.pkl	6 pickles con dgms, cociclos y metadatos por nivel
Notebook	04_interpretacion	hole_centroids() → proyección en Folium + comparación DBSCAN
Dashboard	dashboard/app.py	Portada: métricas globales y tablas de categorías
Dashboard	1_Panorama	Mapa explorador con filtros de nivel, sector, alcaldía
Dashboard	2_Complejos_Simpliciales	Animación Vietoris-Rips interactiva con control de ϵ
Dashboard	3_Persistencia	Diagrama, barcode, Betti — pre-computado o calculado en tiempo real
Dashboard	4_Huecos_de_Cobertura	Mapa de déficit + tabla de zonas prioritarias con coordenadas

El pipeline está diseñado para ser reproducible: los notebooks (01→04) pueden ejecutarse secuencialmente para re-generar todos los artefactos desde el CSV crudo. El dashboard consume los artefactos pre-generados para respuesta inmediata, pero también permite recalculer en tiempo real mediante los controles de la página 3 y 4.

9. Resumen y Aplicación

¿Qué resuelve este proyecto?

El proyecto aplica homología persistente — una herramienta de topología algebraica — para identificar zonas geográficas con déficit de cobertura educativa en la Ciudad de México. A diferencia de métodos clásicos de clustering que detectan dónde hay densidad de escuelas, el análisis topológico detecta dónde NO hay cobertura aunque existan escuelas en los alrededores.

Ventaja sobre métodos tradicionales:

Método	Detecta	No detecta
DBSCAN / K-means	Agrupaciones densas de escuelas (zonas de alta cobertura)	Regiones interiores vacías rodeadas por escuelas
Buffer de distancia simple	Áreas dentro de radio R de alguna escuela	Topología global: si hay 'huecos' en la red
TDA — Homología H_1	Huecos topológicos persistentes en la red de escuelas	Requiere interpretación adicional para política pública

Uso esperado de los resultados:

- Planificación urbana: identificar zonas prioritarias para apertura de nuevos planteles.
- Reasignación de matrícula: redirigir demanda hacia escuelas existentes en perímetro del hueco.
- Análisis comparativo entre niveles: los niveles con mayor persistencia (media técnica) tienen déficits más severos y justifican mayor atención de política pública.
- Extensibilidad: la misma metodología aplica a redes de hospitales, bibliotecas, farmacias, o cualquier servicio geolocalizable.

Limitaciones:

- Datos DENUE registran establecimientos económicos, no necesariamente escuelas activas o con capacidad.
- El umbral $\epsilon = 3,000$ m es razonable pero arbitrario; análisis de sensibilidad con otros valores es recomendable.
- El submuestreo por KMeans (landmarks) puede desplazar ligeramente los centroides de los huecos.
- La persistencia máxima no equivale directamente al número de estudiantes sin acceso.

Documentación generada automáticamente desde el código fuente del proyecto.

Proyecto: Análisis Topológico de Escuelas en CDMX | Rama: Topología Computacional / TDA | Stack: Python · Ripser · Streamlit · Folium · Plotly